La vidéo répond plus vite. Le web entre dans le produit.

TVLens répond aux questions du spectateur sur la vidéo qu'il regarde. Ses modèles ont tourné sur la GX10, un ordinateur IA local (puce NVIDIA GB10, environ 120 Go de mémoire). Au départ : 17,5 s par réponse, les 48 dernières secondes en mémoire, aucun accès au web.

Dans le produit · 30 questions

17,5 → 5,7 s

Délai médian vidéo [1]

Départ → vision sans résumé de frise. Avec ce résumé, la recette rapide répond en 7,1 s.

Dans le produit · 60 questions

28 → 40 /60

Réponses justes avec mémoire [2]

Sans journal → journal du produit. Vision sans résumé de frise ; médiane de 6,2 s.

Hors ligne · 30 questions web

8 → 29 /30

Besoins de web détectés [3]

Mots-clés → décision du modèle (0,65 s). 30/30 avec un titre vidéo, inconnu du produit.

Dans le produit · 18 questions web

0 → 8 /18

14/18 avec le titre · hors ligne [4]

Réponses justes : sans web → F1 sans titre. H4b fournit le titre de la vidéo, encore inconnu du produit.

Les mesures vidéo rapides et F1 retirent le résumé de sujet, écrit par la vision à chaque bloc pour alimenter la frise sur l'écran TV. Le rétablir sans ralentir reste non résolu. Décision web hors ligne : 3 à 4 recherches inutiles sur 60 questions vidéo selon l'exécution.

Trois changements expliquent le gain

Un modèle de réponse plus rapide (Gemma 4), une vision mise en pause pendant la réponse, et un journal des passages anciens que le modèle peut citer. Ce journal condense ce qui précède les 48 dernières secondes, seule fenêtre vidéo directement fournie au modèle.

> Acquis : vitesse, mémoire et premiers résultats web dans le produit. F1, sur 102 questions : vidéo 44/60 contre 39/60 sans web ; web 8/18, vidéo + web 5/12. Limite : 13 blocs de vision perdus.

Le levier principal du web est le titre de la source : 14/18 avec le titre, contre 11/18 pour Codex. Ce gain est mesuré hors ligne, dans un autre paquet de notation ; il reste à l'intégrer au produit.

Notation par des modèles évaluateurs, contre des réponses attendues également préparées par des modèles. Accord avec un évaluateur d'une autre famille : 46/51, soit 90 %. Ce n'est pas une validation humaine.

Ce qui est prouvé.
Ce qui reste à démontrer.

Le produit complet a été mesuré. Il apporte le web sans régression vidéo observée ; la qualité web et la continuité de la vision restent à améliorer.

Prouvé · dans le produit, noté par des modèles

Vitesse : 17,5 → 7,1 s de médiane ; 5,7 s sans résumé de frise. Les réponses justes en moins de 15 s passent de 3 à 20 sur 30. Une répétition confirme le gain de délai.

Mémoire : 28 → 40 réponses justes sur 60 ; faits anciens : 0 → 9 sur 19. Le journal coûte 1,2 s de médiane en plus, avec une vision sans résumé de frise.

Web, en partie : F1 obtient 8/18 sur le web et 5/12 en vidéo + web. La vidéo ne régresse pas : 44/60 contre 39/60 sans web, 7 inventions contre 11 dans le même paquet. Mais 5 questions web ou mixtes sur 30 dépassent 14 s, et 13 blocs de vision sont perdus.

Pas encore prouvé · ce qui reste à faire

Priorité : ticket « titre de la source ». Hors ligne, il porte le web de 8/18 à 14/18 et les mixtes de 5/11 à 7/11, avec 2 inventions contre 5. Le produit ne connaît pas encore ce titre ; il faut le lui fournir puis mesurer le gain dans le produit.

Mesurer T316 et T317, intégrés après F1 : extraction du texte utile et limite de temps web. Rétablir le résumé de frise sans ralentir, réduire les pertes de vision, puis tester le téléviseur et les longues sessions. La configuration testée reste sur une branche de travail, sans livraison sur la version principale.

Écarté dans la forme testée

Résumé calculé à part : 8,1 s au lieu de 6,2 s, avec 14 tranches de 8 s non décrites. Les appels d’outils en plusieurs tours atteignent 156 s de médiane sur une vidéo, pour 18/30 justes contre 20/30. Sélection élaborée du texte web : au mieux autant que le début de page, avec plus d’inventions.

> Comment lire les chiffres
> Jeux : 30 questions vidéo pour la vitesse ; 60 pour la mémoire ; 42 extérieures (18 web, 12 vidéo + web, 12 relectures d’images). Six vidéos : Kennedy, Spring, Tears of Steel, une recette, le CNRS et Artemis.
> « Juste » : note ≥ 2/3, sans invention. Attendus et évaluateurs sont des modèles.
> Dans le produit : vidéos rejouées dans TVLens. Hors ligne : requêtes capturées rejouées pour isoler une brique. Les délais ne sont pas interchangeables.
> Bruit : un rejeu change 7 à 8 verdicts et le score de 1 à 4 points sur 30.

Sources : essais vidéo et mémoire (page 3), F1 et H4b (pages 4–5). Une seule exécution de F1 et de H4b ; aucune validation humaine des scores.

Répondre vite, puis retrouver les passages oubliés.

Chaque tableau utilise le même questionnaire. Les jeux de 30 et de 60 questions ne se comparent pas directement.

La vitesse : modèle, pause de vision et transcription

Configuration	Justes	Justes < 15 s	Toutes < 15 s	Médiane
Configuration de départ	16/30	3/30	7/30	17,5 s
Recette rapide	21/30	20/30	28/30	7,1 s
Vision sans résumé de frise	21/30	21/30	30/30	5,7 s

La recette rapide utilise Gemma 4 (modèle de réponse), met la vision en pause pendant la question et emploie Whisper small (transcription du son). La version allégée reprend cette recette, mais Gemma 3 (modèle de vision) n'écrit plus le résumé de frise.

> Rejouées à l'identique : recette rapide, 17/30 en 8,5 s ; vision sans résumé, 22/30 en 5,2 s. Le gain de délai se reproduit ; le nombre de réponses justes varie jusqu'à 4.

La mémoire : des faits anciens enfin citables

Configuration	Justes	Faits anciens	Inventions	Médiane
Sans journal	28/60	0/19	16/60	5,0 s
Journal expérimental[1]	38/60	6/19	9/60	6,3 s
Journal du produit (J6)	40/60	9/19	10/60	6,2 s

[1] Journal expérimental (injecté par l'outil de mesure). Toutes les réponses arrivent sous 15 s. Faits anciens : éléments sortis de la fenêtre des 48 dernières secondes.

TVLens refuse une réponse qui ne cite pas le passage qui la justifie. Le journal expérimental faisait ainsi rejeter 8 réponses ; celui du produit n'en fait rejeter aucune. Il reste 10 inventions, une de plus que l'objectif fixé avant l'essai (9).

Face au journal expérimental, l'écart de 2 réponses est dans le bruit. Le gain opérationnel est la fin des rejets de citation. Dix des 19 questions anciennes échouent encore.

Sources [1–2] : experiments/essais/2026-10-21-flux-6-videos-gx10/README.md ; 2026-10-22-variantes-nuit-gx10/README.md ; 2026-10-22-flux-60-questions-gx10/README.md ; 2026-10-22-journal-produit-gx10/README.md. J6 est renoté à 38/60 dans le paquet C1 (page 6), contre 40 dans sa première notation. Dans le paquet F1, J6 obtient 39/60 (page 5).

Le titre de la vidéo change le résultat du web.

Le parcours va des pages fournies hors ligne au produit complet. Le titre est le principal levier mesuré ; son intégration reste à faire.

Étape	Cadre	Résultat mesuré
H1 · Fournir des pages	Hors ligne	0 → 26/60 justes ; 30 questions web ou mixtes répétées deux fois.
H2 · Décider par le modèle	Hors ligne	8 → 29/30 besoins web détectés sans titre ; 30/30 avec titre.
H4 · De vraies pages	Hors ligne	Début de page : web 12/18 ; vidéo + web 2/12. Pages collectées à l'avance.
F1 · Produit complet	Dans le produit	Journal + recherche en direct, sans titre : web 8/18 ; vidéo + web 5/12.
H4b · Avec le titre	Hors ligne	Requêtes de F1 : web 14/18 ; vidéo + web 7/11.
C1 · Codex (à distance)	Hors ligne[1]	Recherche web en direct : web 11/18 ; vidéo + web 4/12.

H2 mesure la détection, pas la justesse. [1] C1 reçoit les contextes vidéo capturés. Contextes et paquets de notation diffèrent selon l'étape : ce parcours n'est pas un classement contrôlé.

Avec le titre : huit réponses gagnées, aucune perdue

H4b rejoue les 29 questions où F1 avait cherché : 18 web et 11 mixtes. Journal, consigne et extrait ciblé restent identiques ; seules changent les pages, retrouvées avec le titre dans la requête.

> Même paquet de notation : web 8/18 → 14/18 ; mixtes 5/11 → 7/11 ; inventions 5 → 2 sur 29. Huit gains, aucune perte (+8/−0). Le produit ne connaît pas encore le titre : ticket « titre de la source » à réaliser.

Les étapes précédentes restent utiles, avec leurs limites

H1 : inventions de 2 à 8 sur 60, dont 5 sur des pièges d'actualité. H2 : décision en 0,65 s de médiane ; 3 à 4 recherches inutiles sur 60 questions vidéo sans titre, selon l'exécution.

H4 : début de page et début + extrait font autant, 14/30, avec 3 contre 6 inventions. Le gain antérieur de l'extrait (29 contre 24 sur 60) disparaît. Les trois autres méthodes font moins bien ; le début seul reste la référence.

Appeler des outils puis répondre en plusieurs tours atteint 156 s de médiane sur Spring. Relire d'anciennes images : 4/24 justes, 10 inventions.

Sources [3–4] : README.md des essais decision-web-hors-ligne, web-outils-hors-ligne et web-reel-texte du 22/10, sous experiments/essais/. Détails H4 et H2b en annexe.

Le web fonctionne.
La vision en paie encore le coût.

F1 réunit journal et recherche web, dans TVLens, sur 102 questions. Il utilise le début de page et l'extrait ciblé, sans titre vidéo ni résumé de frise. T316 et T317 sont absents de cette exécution.

La vidéo ne régresse pas dans cet essai

Vidéo · même paquet de notation	Sans web (J6)	Avec web (F1)
Réponses justes	39/60	44/60
Faits anciens / mixtes / récents	9/19 · 7/8 · 23/33	10/19 · 8/8 · 26/33
Inventions	11/60	7/60
Délai médian, attente comprise	6,2 s	7,6 s

F1 gagne 8 questions et en perd 3 face à J6 : aucune régression observée, sans preuve d'un gain général. Quatre recherches sont lancées sur les 60 questions vidéo. Le délai médian augmente de 1,4 s.

Web : un délai propre mesuré, hors file d'attente

Questions	Justes	Médiane	90e centile[1]	> 14 s
Web seul	8/18	12,2 s	15,2 s	3/18
Vidéo + web	5/12	10,6 s	15,0 s	2/12
Vidéo	44/60	7,0 s	10,3 s	0/60

[1] Environ 90 % des réponses arrivent avant ce délai. Mesure : metrics.totalMs, hors file ; centiles recalculés par rang. Posées juste après une question vidéo, les questions web ou mixtes attendent aussi avant traitement ; ce temps s'ajoute au délai perçu.

> Limites mesurées : 5 inventions web ou mixtes sur 30, au-delà du plafond prévu (4). Cinq réponses dépassent 14 s. La vision perd 13 blocs, contre 0 pour J6 : autant de tranches vidéo non décrites. Une réponse est rejetée pour citation invalide.

Des améliorations intégrées, encore non mesurées

T316 extrait le texte principal et fixe une échéance de 14 s ; T317 la limite aux questions qui cherchent sur le web. Leur effet reste non mesuré : arrêter une réponse trop longue ne garantit pas une bonne réponse.

Source : experiments/essais/2026-10-22-produit-complet-web-gx10/README.md, notation-video/, notation-web/ et bruts/. Une exécution sur six vidéos. Critères préalables et résultats en annexe ; les 12 relectures d'images donnent 0/12.

Le local progresse. Les paquets de notation comptent.

C1 compare des réponses aux mêmes contextes vidéo. F1 ajoute une mesure dans le produit ; H4b teste ensuite le titre hors ligne. Chaque essai n'a qu'une exécution.

Essai / cadre	Vidéo	Web seul	Vidéo + web
Local J6 (produit) / H4 (hors ligne) · C1	38/60	12/18	2/12
Codex C1 · hors ligne, web en direct	42/60	11/18	4/12
F1 · dans le produit, sans titre	44/60	8/18	5/12
H4b · hors ligne, avec titre	Non rejoué	14/18	7/11

J6 a été exécuté dans le produit ; sa réponse est renotée dans C1. H4 fournit des pages collectées à l'avance. Codex n'a aucun outil vidéo pour revoir les images : 0/12 en relecture, comme F1. H4b ne reprend que les 29 questions où F1 a cherché.

Trois comparaisons à garder séparées

Paquet C1 : vidéo locale 38/60 contre 42/60 pour Codex ; inventions 12 contre 7. Codex gagne 8 questions et en perd 4 ; l'écart n'est pas statistiquement établi. Sur web + mixtes : 6 inventions locales contre 2. La différence de justesse reste compatible avec le bruit.

Paquet F1 : vidéo 44/60 contre 39/60 pour J6, avec 7 inventions contre 11. Ce 44/60 ne se compare pas directement au 42/60 de C1. J6 a reçu 40/60 initialement, puis 38/60 dans C1 et 39/60 dans F1 : la notation varie.

Paquet H4b : avec titre, 14/18 sur le web dépasse les 11/18 de Codex ; ce constat utilise deux paquets distincts. La comparaison contrôlée est H4b contre F1, renotés ensemble : +8/−0 sur 29 questions, 2 inventions contre 5. Les mixtes H4b portent sur 11 questions, contre 12 pour Codex.

Le délai web complet ne confirme pas l'avantage estimé

Codex : médiane de 5,5 s en vidéo et 10,8 s en web + mixtes, démarrage de l'outil inclus. F1 : délai propre de 12,2 s en web et 10,6 s en mixtes, hors file. Les périmètres diffèrent ; aucun avantage de vitesse web du produit local n'est démontré.

> C1 : mêmes contextes capturés (J6 pour la vidéo, J2 pour les questions extérieures), réponses anonymisées et notées ensemble. Codex gpt-6-luna, raisonnement faible, recherche web intégrée en direct, exécuté sur le Mac. Le titre devient le levier prioritaire du local, sans établir une supériorité générale sur Codex.

Sources : experiments/essais/2026-10-23-comparatif-codex-local/ ; archives F1 et H4b du 22/10. Protocole et détail des paquets de notation en annexe.

Vitesse et perception
Les premières explorations

Types : produit = chaîne TVLens ; hors ligne = brique isolée ; étude = préparation ou analyse. Verdicts : Adopté = choix retenu pour la suite, sans valoir livraison ; Référence = témoin ou point de comparaison ; Répétition = rejeu identique ; Écarté = non poursuivi ; En cours = verdict ouvert ; Reporté = non exécuté, différé. Sauf mention contraire, les délais sont des médianes.

Code	Ce qui change	Type	Vitesse	Pertinence	Verdict
Sans code [a]	Préparer la GX10 et rejouer un court extrait français.	produit	20,6 et 23,7 s	2 réponses ; 1 abstention.	Référence
Sans code [b]	Nuit : comparer cinq et trois images sur des blocs figés.	hors ligne	Comparaison initiale	Qualité non notée dans le bilan technique.	Référence
Sans code [c]	Nuit : autoriser ou suspendre les nouveaux appels vision pendant une question.	produit	Effet du démarrage à froid	Non isolée de façon fiable dans le premier bilan.	Référence
Sans code [d]	Comparer les moteurs Ollama et vLLM pour le texte ; reprise après incident Docker.	hors ligne	Piles non équivalentes	Non notée ; pas de gagnant produit.	Écarté
Sans code [e]	Comparer Ollama et vLLM sur la vision Qwen ; reprise du lot Qwen incluse.	hors ligne	Ollama plus rapide sur cette sonde	Non notée ; configurations différentes.	Écarté
Sans code [f]	StreamingVLM : quatre pilotes d'une autre chaîne vidéo, avec reprises techniques.	hors ligne	Pas de cadence continue établie	Non notée.	Écarté
Sans code [g]	Étendre les réglages de transcription aux trois autres vidéos.	produit	Voir bilans par vidéo	45 réponses acquises ; notation reprise ensuite.	Adopté
Sans code [h]	Confirmer la pause de vision par des exécutions alternées.	produit	Gain variable selon vidéo	Qualité non notée dans ce bilan technique.	Adopté
Sans code [i]	Comparer cinq et trois images par bloc, sans changer de modèle.	hors ligne	Environ 1,5 s gagnée à la première exécution	Non notée dans cette confirmation.	Écarté
Sans code [j]	Simuler une sélection des images, sans supprimer d'appel réel.	étude	Aucun gain réel mesuré	142 blocs candidats sur 667 ; qualité non notée.	Écarté

Fichiers dans experiments/essais/ : [a] 2026-10-20-preparation-gx10/README.md; [b] 2026-10-20-nuit-gx10/README.md; [c] 2026-10-21-consolidation-gx10/README.md; [d] 2026-10-21-reprise-docker-gx10/README.md; [e] 2026-10-20-vision-vllm-gx10/README.md; [f] 2026-10-21-incident-streaming-queue/BILAN.md; [g] 2026-10-21-corpus-etendu-gx10/README.md; [h] 2026-10-21-confirmation-pause-vision-gx10/BILAN.md; [i] 2026-10-21-confirmation-images-gx10/BILAN.md; [j] 2026-10-21-shadow-selection-gx10/README.md.

À retenir : ces explorations orientent la suite. Les incidents et leurs reprises restent rattachés à leur essai ; une exécution réussie ne constitue pas une mesure de pertinence.

Vitesse et perception
Transcrire et décrire

Les réglages de transcription précèdent les modèles de vision. Pour la vision, la vitesse est un délai par bloc ; la justesse est une note sur 3, distincte des réponses aux questions.

Code	Ce qui change	Type	Vitesse	Pertinence	Verdict
Sans code	Transcription Whisper base : référence des premiers lots.	hors ligne	Référence	Référence pour comparer les transcriptions.	Référence
Sans code	Transcription Whisper small, à la place de base.	hors ligne	Environ égale	Spring : 4/5 justes contre 2/5 ; ailleurs comparable.	Adopté
Sans code	Transcription Whisper large-v3-turbo, à la place de base.	hors ligne	1 à 2 s plus lente	Kennedy et Artemis : 5/5 ; Spring : 2/5.	Écarté
E3-réf.	Gemma 3, cinq images : référence des descriptions.	hors ligne	6,7 s/bloc	Justesse 1,57/3 ; 27/36 blocs avec invention.	Référence
E3-a	Vision Qwen 2B.	hors ligne	8,2 s/bloc	Non notée ; format de sortie invalide 16/36.	Écarté
E3-b	Vision Qwen 4B.	hors ligne	17,0 s/bloc	Non notée ; format invalide 8/36.	Écarté
E3-c	Vision Qwen 8B.	hors ligne	15,9 s/bloc	Non notée ; format invalide 3/36.	Écarté
E3-d	Vision Gemma 4 avec raisonnement.	hors ligne	13,7 s/bloc	Non notée ; format valide 36/36.	Écarté
E3-e	Vision Qwen 30B-A3B.	hors ligne	11,3 s/bloc	Non notée ; format valide 36/36.	Écarté
E3-f	Gemma 3 avec trois images au lieu de cinq. Terminé au rattrapage.	hors ligne	5,6 s/bloc	Justesse 1,60/3 ; 21/36 blocs avec invention.	Écarté
E3b	Gemma 4 avec raisonnement désactivé.	hors ligne	4,2 s/bloc	Justesse 2,58/3 ; 4/36 blocs avec invention.	Référence

Source commune : experiments/essais/2026-10-21-variantes-gx10/README.md. Sources : 2026-10-21-vision-hors-ligne-gx10/README.md.

À retenir : Gemma 4 sans raisonnement gagne sur les descriptions isolées. Son essai dans la chaîne complète ne gagne pourtant pas de réponse juste face à la recette rapide.

Vitesse et perception
La chaîne vidéo complète

Ces essais rejouent les vidéos dans TVLens. Les réglages intermédiaires restent visibles pour comprendre comment la référence rapide a été obtenue.

Code	Ce qui change	Type	Vitesse	Pertinence	Verdict
E1	Mesurer la configuration de départ, sans modification.	produit	17,5 s	16/30 justes ; 7 rapides, dont 3 justes (< 15 s).	Référence
E4-G	Remplacer le modèle de réponse par Gemma 4, sur trois vidéos.	produit	9,1 à 12,2 s selon vidéo	9/15 justes.	Adopté
E4-GP	Ajouter la pause de vision pendant les questions.	produit	5,2 à 7,2 s selon vidéo	8/15 justes ; toutes < 15 s.	Adopté
E4-GPS	Ajouter la transcription Whisper small.	produit	5,2 à 9,4 s selon vidéo	10/15 justes ; toutes < 15 s.	Adopté
E5-GPS	Recette rapide : Gemma 4, pause vision, Whisper small ; six vidéos.	produit	7,1 s	21/30 justes ; 5 inventions.	Adopté
E5-GPSV	Recette rapide avec la vision Gemma 4 sans raisonnement.	produit	6,8 s	20/30 justes ; 5 inventions.	Écarté
N1	Rejouer la recette rapide à l'identique.	produit	8,5 s	17/30 justes ; 8 statuts changent.	Répétition
N2	Vision allégée : retirer le résumé de sujet de la recette rapide.	produit	5,7 s	21/30 justes ; 4 inventions.	Référence
N6	Rejouer la vision allégée à l'identique.	produit	5,2 s	22/30 justes ; 7 statuts changent.	Répétition
J1	Combiner vision Gemma 4 et retrait du résumé de sujet. Reporté ; non exécuté.	étude	Non mesurée	Non mesurée.	Reporté

[1] Source commune : experiments/essais/2026-10-21-variantes-gx10/README.md. Sources : 2026-10-21-flux-6-videos-gx10/README.md ; 2026-10-22-variantes-nuit-gx10/README.md.

À retenir : la vision allégée donne la référence de vitesse. Les répétitions confirment le délai tout en montrant que le score de pertinence peut varier. Les trois vidéos de la première recette sont réutilisées dans son extension à six vidéos.

Modèle de questions
Choisir le bon compromis

Les modèles sont d’abord comparés seuls, puis le choix est vérifié dans TVLens. « Gardée » signifie ici : réponse juste dont les citations sont acceptées par le produit.

Code	Ce qui change	Type	Vitesse	Pertinence	Verdict
E2-réf.	Qwen 27B : référence hors ligne.	hors ligne	9,2 s	17/30 gardées ; 5 inventions.	Référence
E2-a	Qwen 27B avec prédiction de plusieurs éléments de texte à la fois (MTP).	hors ligne	9,3 s	17/30 gardées ; aucun gain.	Écarté
E2-b	Qwen 35B-A3B : modèle qui n’active qu’une partie de ses paramètres.	hors ligne	3,5 s	18/30 gardées ; 8 inventions.	Écarté
E2-c	Même Qwen avec accélération MTP.	hors ligne	3,1 s	18/30 gardées ; 7 inventions.	Écarté
E2-d	Gemma 4, version 26B-A4B.	hors ligne	4,6 s	20/30 gardées ; 4 inventions.	Adopté
E2-e	Qwen accéléré avec raisonnement plus long.	hors ligne	17,7 s	8/30 gardées ; 8/30 sorties invalides.	Écarté
E2-x	Qwen dans un autre format de poids, incompatible avec la pile Linux testée. Abandonné sans essai.	hors ligne	Non mesurée	Non mesurée.	Écarté
G3	Désactiver MTP, l’accélération qui prédit plusieurs éléments de texte à la fois.	hors ligne	18,4 s sans ; 10,4 s avec	Même longueur de sortie ; qualité non renotée.	Référence
N4	Vérifier Qwen 35B-A3B accéléré dans TVLens, avec pause et Whisper small.	produit	6,1 s	18/30 justes ; 7 inventions.	Écarté

Source commune : experiments/essais/2026-10-21-variantes-gx10/README.md. Sources : 2026-10-21-questions-hors-ligne-gx10/README.md.

À retenir : Gemma 4 offre le meilleur compromis testé. Le modèle le plus rapide seul invente davantage. L’accélération MTP était déjà active dans la référence : l’activer à nouveau n’ajoute rien.

Mémoire
Comparer les formes du journal

Ces essais hors ligne isolent l’accès aux passages anciens. Les scores à 60 réponses peuvent compter deux exécutions des mêmes 30 questions.

Code	Ce qui change	Type	Vitesse	Pertinence	Verdict
G2-A	Sans journal : référence du premier test mémoire.	hors ligne	10,5 s	38/60 justes ; 14 inventions.	Référence
G2-b	Ajouter un journal compact des passages anciens.	hors ligne	13,4 s	47/60 justes ; 6 inventions.	Référence
G2-c	Retrouver six passages anciens par proximité de sens.	hors ligne	11,0 s	41/60 justes ; 11 inventions.	Écarté
G5-A	Sans journal : référence du second test mémoire.	hors ligne	4,2 s	45/60 justes ; 13 inventions.	Référence
G5-B	Journal complet, placé avant les passages récents.	hors ligne	5,5 s	49/60 justes ; 7 inventions.	Adopté
G5-C	Une entrée par sujet ; plusieurs changements simultanés. Retiré avant exécution.	hors ligne	Non mesurée	Non mesurée.	Écarté
G5-D	Limiter le journal à 3 000 caractères.	hors ligne	4,7 s	46/60 justes ; 12 inventions.	Écarté
G5-E	Placer le journal après les passages récents.	hors ligne	5,5 s	45/60 justes ; 12 inventions.	Écarté
G5-F	Essayer sans journal, puis avec journal seulement en cas d’abstention. Calculé sans nouvel appel.	hors ligne	4,3 s reconstituées	45/60 justes ; 14 inventions.	Écarté

Source commune : experiments/essais/2026-10-21-variantes-gx10/README.md. Sources : 2026-10-21-serie-g-gx10/README.md ; 2026-10-22-journal-hors-ligne-gx10/README.md.

À retenir : le journal complet est le meilleur candidat. Attendre une abstention ne suffit pas : sans le fait ancien, le modèle peut inventer au lieu de refuser de répondre.

Mémoire
Du journal expérimental au produit

Ces essais vérifient le journal dans la chaîne vidéo et isolent les problèmes de citation. Ils utilisent d'abord 30 questions, puis un jeu élargi à 60.

Code	Ce qui change	Type	Vitesse	Pertinence	Verdict
N3	Ajouter le journal seul à la recette rapide.	produit	9,1 s	21/30 justes ; 4/6 faits anciens.	Écarté
N5	Ajouter le journal à la vision allégée. Terminé en deux lots.	produit	6,8 s	22/30 justes ; 4 inventions.	Référence
J2	Vision allégée sans journal, sur 60 questions.	produit	5,0 s	28/60 justes ; 0/19 anciennes ; 16 inventions.	Référence
J3	Même recette avec journal expérimental (injecté par l'outil de mesure).	produit	6,3 s	38/60 justes ; 6/19 anciennes ; 9 inventions.	Référence
J6	Journal construit dans le produit, avec passages anciens citables.	produit	6,2 s	40/60 justes ; 9/19 anciennes ; 10 inventions.	Adopté
J2bis	Répéter à l'identique la référence sans journal. Retiré avant exécution.	étude	Non mesurée	Non mesurée.	Écarté
J3bis	Répéter à l'identique le journal expérimental (injecté par l'outil de mesure). Retiré avant exécution.	étude	Non mesurée	Non mesurée.	Écarté

[2] Source commune : experiments/essais/2026-10-21-variantes-gx10/README.md. Sources : 2026-10-22-flux-60-questions-gx10/README.md ; 2026-10-22-journal-produit-gx10/README.md.

À retenir : le journal du produit supprime les rejets de citation et améliore la justesse vidéo sans web. Il reste 10 inventions, soit une de plus que le maximum prévu. La branche produit n'est pas une preuve de livraison sur la branche principale.

Résumé de sujet
Préserver la frise sans ralentir

Le résumé de sujet sert aux cartes de la frise TV. L'enlever accélère la vision ; ces essais cherchent à conserver cette fonction autrement.

Code	Ce qui change	Type	Vitesse	Pertinence	Verdict
G4-a	Retirer le résumé cumulatif des descriptions visuelles.	hors ligne	5,2 s/bloc contre 6,7	Non notée ; descriptions courtes peu changées.	Référence
G4-b	Limiter ce résumé à 300 caractères.	hors ligne	6,5 s/bloc	Non notée ; retards extrêmes réduits.	Écarté
J4	Calculer le résumé après chaque bloc, en arrière-plan, sans journal.	produit	6,3 s par réponse	Non notée ; 106 tranches de 8 s non décrites.	Écarté
J5	Avec journal expérimental, calculer le résumé tous les quatre blocs ou au changement de sujet. Interrompu ; remplacé.	produit	Non consolidée	Non notée.	Écarté
J5b	Avec journal du produit, calculer le résumé tous les quatre blocs ou au changement de sujet.	produit	8,1 s par réponse	Non notée ; 14 tranches de 8 s non décrites.	Écarté

Source commune : experiments/essais/2026-10-21-variantes-gx10/README.md. Sources : 2026-10-21-serie-g-gx10/README.md ; 2026-10-22-resume-asynchrone-gx10/README.md.

À retenir : le calcul en parallèle concurrence encore la vision sur la même machine. Les deux versions terminées échouent sur la cadence ; aucune note de qualité du résumé ne doit leur être attribuée. La vision allégée est une référence expérimentale, pas la suppression décidée d'une fonction TV.

Web et outils
Faire appeler les bons outils

Ces essais séparent le mécanisme d’appel des outils de la qualité des réponses. Un appel réussi ne prouve pas que le modèle répond juste.

Code	Ce qui change	Type	Vitesse	Pertinence	Verdict
G1-b	Retirer le format de sortie imposé au premier tour pour autoriser les outils.	hors ligne	5,1 s au premier tour	20/20 appels outil ; 0/40 avec format imposé.	Référence
G1-c	Témoin : répondre sans outil disponible.	hors ligne	11,3 s	20/20 sorties valides ; qualité non notée.	Référence
E6-GPSVT	Recette rapide + vision Gemma 4 ; outils au premier tour, réponse au second.	produit	Spring : 156 s	18/30 justes ; 17 justes < 15 s.	Écarté
E7-GPSVJT	Même chaîne à deux tours, avec journal mémoire.	produit	11,8 s ; Spring : 146 s	17/30 justes ; 3 erreurs.	Écarté
H1-A	Questions web : produit initial, sans pages.	hors ligne	3,4 s	0/60 justes ; 2 inventions.	Référence
H1-A2	Autoriser une réponse web, mais sans fournir de pages.	hors ligne	3,0 s	3/60 justes.	Écarté
H1-B	Fournir trois passages de pages collectées pour les tests, retrouvés depuis la question.	hors ligne	4,9 s	26/60 justes ; 8 inventions.	Référence
H1-C	Laisser le modèle demander lui-même la recherche, en deux tours.	hors ligne	Boucles et sorties invalides	Non notée.	Écarté
H1-O0	Questions sur des images anciennes, sans journal.	hors ligne	3,1 s	0/24 justes.	Référence
H1-OJ	Même jeu d’images anciennes avec journal.	hors ligne	4,3 s	0/24 justes.	Écarté
H1-OI	Journal + outil qui relit un ancien extrait vidéo.	hors ligne	8,7 s	4/24 justes ; 10 inventions.	Écarté

Source commune : experiments/essais/2026-10-21-variantes-gx10/README.md. Sources : 2026-10-22-web-outils-hors-ligne-gx10/README.md.

À retenir : fournir les preuves avant la réponse aide davantage que multiplier les tours d’outils. Les 60 réponses web et les 24 réponses sur images anciennes sont respectivement 30 et 12 questions répétées deux fois.

Web et outils
Décider et préparer la recherche

Ces essais évaluent la décision de chercher puis le texte fourni depuis des pages collectées pour les tests. La vitesse indiquée concerne l'étape testée, pas le web complet.

Code	Ce qui change	Type	Vitesse	Pertinence	Verdict
S1	Installer SearXNG, le moteur de recherche hébergé sur la GX10.	étude	3,0 s par requête test	50 résultats ; qualité non notée.	Adopté
H2-P	Faire décider le modèle et écrire la requête, sans titre de vidéo.	hors ligne	Décision : 0,65 s pour le lot H2	29/30 besoins détectés ; 3-4/60 recherches inutiles.	Adopté
H2-PT	Même décision avec le titre de la vidéo.	hors ligne	Même lot de décision	30/30 détectés ; 3/60 recherches inutiles.	Référence
H2-PQ	Répondre avec les pages retrouvées par la requête sans titre.	hors ligne	4,3 s	21/58 justes ; 4 inventions.	Écarté
H2-PTQ	Répondre avec les pages retrouvées par la requête avec titre.	hors ligne	4,6 s	26/60 justes ; 6 inventions.	Référence
H2b-FQ	Fusionner les passages retrouvés par la requête du modèle et la question brute.	hors ligne	4,3 s	21/60 justes ; 5 inventions.	Écarté
H2b-PH	Fournir le début de trois pages, jusqu'à 2 500 caractères chacune.	hors ligne	5,3 s	24/60 justes ; 2 inventions.	Référence
H2b-PW	Début de page et extrait contenant les mots de la question.	hors ligne	5,7 s	29/60 justes ; 3 inventions.	Référence
T1	Intégrer la recherche, les pages et la validation des sources dans le produit (tickets 308-311). Code intégré sur branche.	produit	Pas de mesure propre	Pas de score propre.	Adopté
T314	Intégrer la décision de chercher par le modèle. Code intégré sur branche.	produit	Pas de mesure propre	Évaluée hors ligne ci-dessus.	Adopté

[3] experiments/essais/2026-10-22-decision-web-hors-ligne-gx10/README.md ; notation-h2b/notes.json ; bruts-h2b/calls.jsonl.gz. SearXNG et intégrations : registre 2026-10-21-variantes-gx10/README.md.

La décision de chercher est utile sans titre vidéo. L'avantage de l'extrait ciblé sur les pages des premiers tests ne se confirme pas sur les vraies pages collectées pour H4.

Web et outils
Choisir le texte des vraies pages

H4 est hors ligne : 30 questions, une exécution par variante, après collecte des pages. Ses délais ne comptent que la réponse, sans décision ni recherche.

Code	Ce qui change	Type	Vitesse	Pertinence	Verdict
H4-V0	Fournir le début de chaque page réelle.	hors ligne	6,2 s	14/30 justes ; 3 inventions.	Référence
H4-V1	Début de page + extrait ciblé par les mots de la question.	hors ligne	6,2 s	14/30 justes ; 6 inventions.	Écarté
H4-V2	Fusionner deux recherches et sélectionner un extrait.	hors ligne	6,4 s	12/30 justes ; 6 inventions.	Écarté
H4-V3	Classer les passages par mots communs, méthode BM25.	hors ligne	5,2 s	10/30 justes ; 8 inventions.	Écarté
H4-V4	Classer les passages selon leur proximité de sens.	hors ligne	5,6 s	8/30 justes ; 7 inventions.	Écarté
T315	Intégrer le début de page accompagné d'un extrait ciblé. Code intégré sur branche.	produit	Pas de mesure propre	Pas de gain sur vraies pages dans cette exécution.	Écarté
Sans code	Étudier la recherche inversée d'image pour retrouver une source depuis une image. Étude seule ; non exécuté.	étude	Non mesurée	Aucun cas utile identifié dans le jeu actuel.	Écarté

[4] experiments/essais/2026-10-22-web-reel-texte-gx10/README.md ; notation/ ; bruts/. Recherche inversée : étude de campagne, sans essai.

Le début de page reste la référence simple. « Écarté » pour l'extrait ciblé est une recommandation issue de H4, pas une suppression du code : F1 et H4b conservent cet extrait. La recherche inversée reste hors de cette campagne.

Web et outils
Le produit complet et le titre

F1 est terminé et mesuré dans le produit. H4b isole ensuite le titre hors ligne. Une intégration de code sans essai ne vaut pas résultat mesuré.

Code	Ce qui change	Type	Vitesse	Pertinence	Verdict
F1	Terminé : journal + web sur 102 questions ; sans titre ni résumé de frise.	produit	Web : 12,2 s hors file	Vidéo 44/60 ; web 8/18 ; mixtes 5/12. 13 blocs de vision perdus.	Référence
H4b	Terminé : remplacer les pages par celles retrouvées avec le titre ; 29 requêtes de F1.	hors ligne	Délai produit non mesuré	Web 14/18 ; mixtes 7/11 ; 2 inventions contre 5 ; +8/−0.	Adopté
T316	Intégré après F1 : extraction du texte principal (Readability) et échéance de 14 s.	produit	Non mesurée	Non mesurée dans le produit. Absent de F1.	En cours
T317	Intégré après F1 : limiter l'échéance aux questions qui cherchent sur le web.	produit	Non mesurée	Non mesurée dans le produit. Absent de F1.	En cours
F1b	Abandonné : seconde exécution conditionnelle avec fusion et extrait ciblé. Non exécuté.	produit	Non mesurée	Non mesurée.	Écarté
Titre de la source	Ticket à faire : rendre le titre disponible dans le produit, puis mesurer son effet.	étude	Non mesurée	Gain isolé dans H4b ; pas encore dans le produit.	En cours

[4] Sources : experiments/essais/2026-10-22-produit-complet-web-gx10/README.md ; 2026-10-22-web-reel-texte-gx10/README.md, H4b. F1b : registre 2026-10-21-variantes-gx10/README.md.

F1 prouve un premier usage du web sans régression vidéo observée, avec des pertes de vision. H4b désigne le titre comme priorité. « Adopté » exprime le choix pour la suite, sans valoir livraison ; T316 et T317 attendent encore une mesure.

Oracles et méthode
Construire et contrôler la mesure

Ces travaux préparent les réponses attendues et contrôlent les mesures. Ils ne produisent donc pas de score de qualité du produit.

Code	Ce qui change	Type	Vitesse	Pertinence	Verdict
Sans code	Relecture initiale : geler les fiches et anonymiser les réponses.	étude	Sans objet	Attendus provisoires ; validation nécessaire.	Référence
Sans code	Vérifier les preuves des fiches directement dans les médias.	étude	Sans objet	8 questions : 5 confirmées, 3 à corriger.	Référence
Oracle v2	Préparer transcriptions et images, puis faire rédiger et arbitrer les réponses attendues.	étude	Sans objet	30 attendus : 21 confirmés, 8 corrigés, 1 mal posé.	Référence
Sans code	Noter les réponses anonymisées ; rechercher les pistes techniques.	étude	Sans objet	Grille commune, sans validation humaine.	Référence
O60 / v3	Étendre le jeu vidéo de 30 à 60 questions.	étude	Sans objet	30 nouvelles : 15 acceptées, 15 corrigées.	Référence
O4 / v4	Préparer les questions web et outils, avec des pages conservées.	étude	Sans objet	42 questions ; 51/54 pages disponibles.	Référence
Sans code	Consolider les campagnes initiales et réanalyser les ablations sans relancer de modèle.	étude	Recalculs hors machine	Distingue vitesse, pertes et qualité non notée.	Référence
Sans code	Audit indépendant des fichiers, chiffres et traces de la première nuit.	étude	Sans objet	Limites de comparaison et de notation signalées.	Référence
Audit juges	Faire renoter à l'aveugle par une autre famille de modèles.	étude	Sans objet	46/51 mêmes statuts pertinent ou non.	Référence
Revues	Relire périodiquement les résultats, la méthode et l'ordre des essais. Effectuées pendant la campagne.	étude	Sans objet	Contrôle méthodologique ; pas un score produit.	Référence

Sources : 2026-10-21-oracle-notation-recherche-gx10/README.md ; 2026-10-21-preuves-medias-fiches-gx10/README.md ; 2026-10-22-oracle-60-questions-gx10/README.md ; 2026-10-22-oracle-v4-web-outils-gx10/README.md ; 2026-10-21-variantes-gx10/revues/README.md.

À retenir : les attendus et les évaluateurs sont eux-mêmes des modèles. Les contrôles renforcent la comparaison, sans établir une vérité humaine. Les notes et les données brutes restent les preuves à conserver pour clore le dossier.

C1 · Contexte identique, notation commune

La comparaison C1 utilise des contextes capturés et une recherche à distance en direct. Elle ne rejoue pas toute la chaîne vidéo dans Codex.

Vidéo par âge des faits · paquet C1

Faits nécessaires	Local J6	Codex C1
Récents · 33 questions	22/33	24/33
Mixtes · 8 questions	7/8	7/8
Anciens · 19 questions	9/19	11/19
Total	38/60	42/60

« Mixtes » désigne ici l'âge des faits vidéo, pas la catégorie vidéo + web. Les contextes sont identiques à ceux reçus par le local : J6 pour la vidéo, J2 pour les 42 questions extérieures. Codex n'a pas les outils vidéo de TVLens ; son 0/12 ne mesure donc pas une capacité à relire des images.

C1 : Codex gpt-6-luna, raisonnement faible, recherche web intégrée ; codex exec lancé sur le Mac le 22/10 vers 22:15 UTC. Une recherche est lancée pour 13/18 questions web et 8/12 questions mixtes. Médiane : 5,5 s en vidéo ; 10,8 s en web + mixtes, 90e centile 19,2 s, démarrage de l'outil inclus.

Les renotations ne remplacent pas les scores initiaux

Paquet de notation	J6 vidéo justes / inventions	H4 web + mixtes justes / inventions
Notation initiale de chaque essai	40/60 · 10	14/30 · 3
C1	38/60 · 12	14/30 · 6
F1	39/60 · 11	14/30 · 5

Chaque paquet anonymise les réponses comparées, selon la règle « note ≥ 2/3 sans invention ». Face-à-face vidéo C1 : +8/−4 pour Codex, p = 0,388 (test binomial bilatéral sur 12 désaccords ; une petite valeur de p indique un résultat peu probable si aucun système n'a l'avantage). F1 et H4b sont notés dans d'autres paquets : ils ne permettent pas un nouveau face-à-face contrôlé contre la vidéo C1.

L'ancienne estimation locale d'environ 8,6 s additionnait trois médianes séparées : décision 0,65 s, collecte des pages 1,7 s, réponse 6,2 s. Ce n'est pas une médiane de bout en bout. F1 fournit désormais un délai propre mesuré : 12,2 s sur le web seul.

Quota Codex : moins de 1 % selon le suivi de campagne ; jauge hebdomadaire arrondie à 8 % avant et après, sans mesure de coût. Sources : experiments/essais/2026-10-23-comparatif-codex-local/ (README.md, notation-video/, notation-web/, bruts/). Renotation F1 : notation-video/ et notation-web/ de son archive.

F1 et H4b · Ce qui a été testé

F1 est terminé. H4b teste ensuite le titre en conservant les requêtes de réponse de F1. T316 et T317 ne sont mesurés dans aucun de ces deux essais.

F1 · Configuration et critères fixés avant le départ

Branche essai/f1-journal-web, révision cfa0bf8 : journal du produit + recherche SearXNG + décision par le modèle + début de page et extrait ciblé (T315). Vision sans résumé de frise, aucun titre vidéo. Les branches journal et web sont réunies pour l'essai, sans fusion dans main. Les 102 questions comprennent 60 vidéo et 42 extérieures.

Critère	Seuil préalable	Résultat F1
Justesse web + mixtes avec source validée	≥ 12/30	13/30 · atteint
Inventions web + mixtes	≤ 4/30	5/30 · non atteint
Justesse vidéo	≥ 37/60 (J6 initial − 3)	44/60 · atteint
Recherches inutiles en vidéo	≤ 5/60	4/60 · atteint
Médiane web + mixtes hors file	≤ 15 s	11,6 s · atteint

Le seuil vidéo avait été fixé sur J6 à 40/60. La comparaison finale renote J6 à 39/60, avec 11 inventions contre 7 pour F1. F1 gagne 8 questions et en perd 3 ($p \approx 0{,}23$). Les 7 inventions extérieures de F1 se répartissent en 5 web ou mixtes et 2 relectures d'images ; ces dernières donnent 0/12. Les 13 réponses web ou mixtes justes ont une source validée.

H4b · Isoler le titre, hors ligne

Les 29 requêtes où F1 avait cherché sont rejouées : 18 web et 11 mixtes. Les pages viennent des requêtes H2 avec titre ; journal, consigne et sélection T315 sont conservés. Titres des pages YouTube du corpus, nom de fichier pour Kennedy. Une question mixte sans recherche dans F1 reste hors du rejeu.

Même paquet H4b	F1 sans titre	H4b avec titre
Web seul	8/18	14/18
Vidéo + web	5/11	7/11
Inventions, toutes catégories	5/29	2/29

Huit gains, aucune perte : artemis-w2, cnrs-w2, cnrs-w3, cuisine-m1, cuisine-w1, spring-m2, spring-w2, tears-w2. Test binomial bilatéral : $p = 0{,}0078$. Aucun délai produit avec titre n'est mesuré. Le ticket « titre de la source » reste à faire.

Sources : experiments/essais/2026-10-22-produit-complet-web-gx10/ (README.md, plans/, notation-video/, notation-web/, bruts/) ; 2026-10-22-web-reel-texte-gx10/ (README.md, notation-h4b/, bruts-h4b/).